UTS Pembelajaran Mesin - Kelas C

Analisis & Prediksi Produksi Kakao Indonesia Menurut Provinsi

Penerapan Exploratory Data Analysis (EDA) dan Algoritma Regresi Linier Sederhana Menggunakan Python

Zhalsabila Amalia Putri
NIM: 202431181

Tahapan Kerja Machine Learning

01

Dataset & Problem

Sumber data resmi Kementan dan konteks masalah bisnis.

02

EDA & Clearing

Pembersihan missing value dan analisis persebaran outlier.

03

Kalkulasi Manual

Perhitungan persamaaan regresi linier step-by-step.

04

Python & Evaluasi

Implementasi Jupyter Notebook dan evaluasi R^2 Score.

SUMBER & PROFIL DATA

Informasi Dataset Produksi Kakao

NAMA DATASET

Produksi Kakao Perkebunan Rakyat, Negara, Swasta Menurut Provinsi (2020-2024)

INSTANSI PORTAL ASAL

Direktorat Jenderal Perkebunan / Satu Data Pertanian Kementan

DIMENSI DATA INITIAL

190 Nilai Observasi | 38 Provinsi × 5 Tahun Pengamatan



LATAR BELAKANG & TUJUAN

Business Understanding

Rumusan Masalah

Ketimpangan produksi kakao antarprovinsi sangat besar, disertai keberadaan data yang belum lengkap. Diperlukan analisis historis untuk memprediksi volume produksi mendatang.

Tujuan Analisis

Mengidentifikasi pola sebaran data, menangani missing value, menganalisis outlier, dan membangun model regresi linear yang presisi.

Target Evaluasi

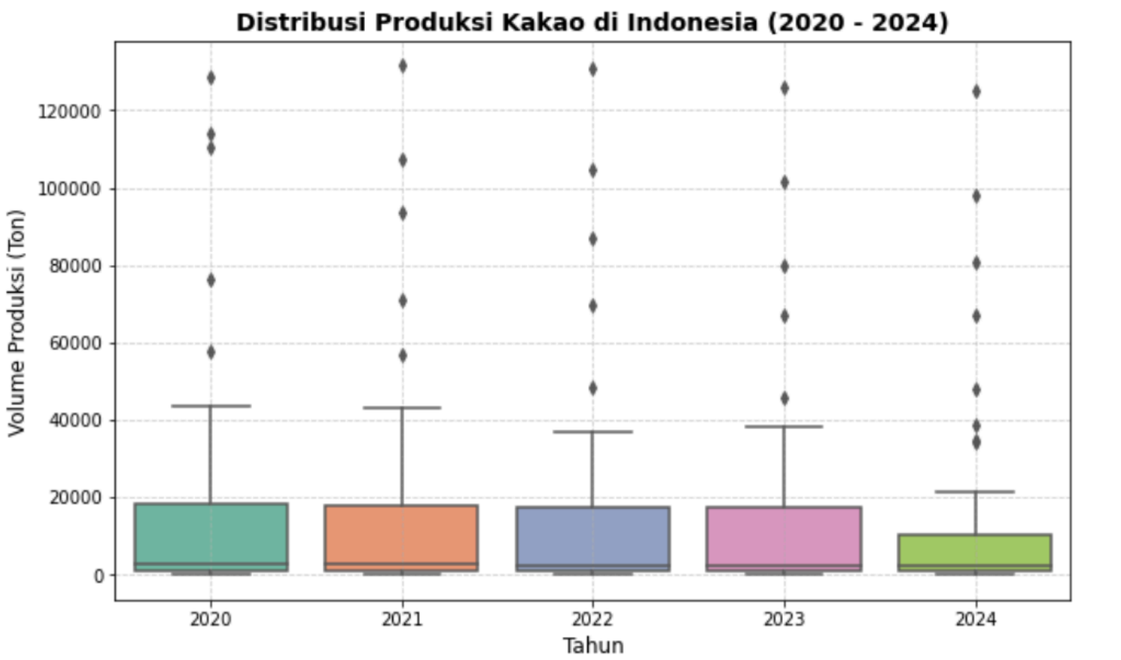
Model performa tinggi dicapai jika koefisien determinasi R^2 minimal 0.90 dan tingkat kesalahan prediksi relatif rendah.

EKSPLORASI DATA

Exploratory Data Analysis & Insight

Temuan Kunci EDA

- **Pola Sebaran: Distribusi produksi sangat timpang antar wilayah.**
- **Produsen Utama: Sulawesi Tengah mencatat rekor tertinggi (125.202 Ton).**
- **Data Rata-Rata: Rerata nasional tahun 2024 bernilai 16.239 Ton.**
- **Outlier Alami: 8 provinsi teridentifikasi sebagai pencilan valid.**



PERBANDINGAN PRODUKSI (2024)

Sulteng (Tertinggi) — **125.202 Ton**

Batas Atas IQR — **24.094 Ton**

Rata-Rata Nasional — **16.239 Ton**

PEMBERSIHAN & PREPARASI DATA

Pembersihan & Preparasi Data

1. Handling Missing Value

Konversi karakter (-) ke NaN. Terdapat 17 nilai kosong. DKI Jakarta dihapus penuh. Provinsi pemekaran Papua dipertahankan karena data 2023-2024 lengkap.

2. Penanganan Outlier

Deteksi IQR menemukan 8 provinsi outlier. Nilai ekstrem dipertahankan karena mencerminkan fakta riil daerah pusat produksi kakao nasional.

3. Dataset Akhir (Model Ready)

Dataset bersih memiliki 37 provinsi. Variabel X diisi data produksi tahun 2023 dan variabel Y diisi target produksi tahun 2024.

SIMULASI MANUAL (SOAL 2)

Perhitungan Manual Regresi Linear Sederhana

Perhitungan manual dilakukan untuk memahami proses pembentukan model regresi linear sederhana sebelum diterapkan menggunakan Python.
Variabel yang digunakan:

X = Produksi kakao tahun 2023.
Y = Produksi kakao tahun 2024.
Jumlah sampel = 10 provinsi.

No.	Provinsi	Produksi 2023 (X)	Produksi 2024 (Y)
1	Jawa Barat	696	707
2	Jawa Tengah	1.378	1.307
3	DI Yogyakarta	1.893	2.026
4	Jawa Timur	20.007	10.563
5	Banten	2.100	2.121
6	Bali	4.399	4.869
7	Nusa Tenggara Barat	2.569	2.589
8	Nusa Tenggara Timur	20.897	21.083
9	Kalimantan Barat	678	604
10	Kalimantan Tengah	1.583	1.605

SIMULASI MANUAL (SOAL 2)

Tabel Penolong Regresi Manual (n=10)

A	B	C	D	E	F	G
No.	Provinsi	X	Y	X^2	Y^2	XY
1	Jawa Barat	696	707	484.787	499.973	492321,4199
2	Jawa Tengah	1.378	1.307	1.898.120	1.707.532	1800305,728
3	DI Yogyakarta	1.893	2.026	3.585.115	4.104.392	3835976,899
4	Jawa Timur	20.007	10.563	400.295.959	111.580.733	211341705,4
5	Banten	2.100	2.121	4.408.204	4.496.817	4452290,058
6	Bali	4.399	4.869	19.349.774	23.706.344	21417571,96
7	Nusa Tenggara Barat	2.569	2.589	6.600.532	6.704.992	6652557,01
8	Nusa Tenggara Timur	20.897	21.083	436.681.912	444.497.806	440572527,3
9	Kalimantan Barat	678	604	459.955	365.400	409960,3706
10	Kalimantan Tengah	1.583	1.605	2.505.287	2.574.837	2539824,41
	Jumlah Total	56.200	47.474	876.269.645	600.238.826	693.515.041

- n = 10
- $\Sigma X = 56.200,33$
- $\Sigma Y = 47.474,04$
- $\Sigma XY = 693.515.040,53$
- $\Sigma X^2 = 876.269.645,31$
- $\bar{X} = 5.620,03$
- $\bar{Y} = 4.747,40$

Rumus mencari intercept (a):

$$a = \bar{Y} - b\bar{X}$$

$$a = 4.747,4 - (0,7614 \times 5.620)$$

$$a = 468,33$$

Rumus mencari slope (b):

$$b = \frac{n\sum XY - (\sum X)(\sum Y)}{n\sum X^2 - (\sum X)^2}$$

$$b = \frac{10(693.515.041) - (56.200)(47.474)}{10(876.269.645) - (56.200)^2}$$

$$b = \frac{6.935.150.410 - 2.668.039.240}{8.762.696.450 - 3.158.440.000}$$

$$b = \frac{4.267.111.170}{5.604.256.450}$$

$$= 0,7614$$

PERHITUNGAN MATEMATIS

Hasil Persamaan Regresi Manual

PERSAMAAN REGRESI REKAPITULASI

$\hat{Y} = 468{,}33 + 0{,}7614(X)$

Slope (b) = 0,7614: Setiap kenaikan 1 ton produksi tahun 2023, memprediksi kenaikan 0,7614 ton pada tahun 2024.

Intercept (a) = 468,33: Estimasi basis produksi jika tahun sebelumnya bernilai nol.

SIMULASI PREDIKSI: JAWA BARAT

Diketahui produksi 2023 (X) = 696 Ton

$\hat{Y} = 468{,}33 + 0{,}7614 * (696)$
$\hat{Y} = 468{,}33 + 529{,}93$
$\hat{Y} = 998{,}26$ Ton

Nilai Aktual: **707 Ton** |

Selisih nilai dipengaruhi oleh dinamika iklim dan kondisi pertanaman lokal.

IMPLEMENTASI PROGRAM

Pemodelan Regresi Menggunakan Python

1. Pemodelan

In [6]:
```
# 202431181_Zhalsabila Amalia Putri

# 2. Membagi Data Training dan Testing
x_train, x_test, y_train, y_test = tts(
    x, y, test_size=0.2, random_state=0
)
```

In [7]:
```
# 202431181_Zhalsabila Amalia Putri

# 3. Membuat dan Melatih Model
model = LinearRegression()
model.fit(x_train, y_train)
```

Out[7]:
```
LinearRegression()
```

In [8]:
```
# 202431181_Zhalsabila Amalia Putri

# 4. Melakukan Prediksi pada Data Uji
y_pred = model.predict(x_test)
```

In [9]:
```
# 202431181_Zhalsabila Amalia Putri

print("Hasil Prediksi:")
print(y_pred)
```

```
Hasil Prediksi:
[  505.64996752  -267.91995367  2217.88360533   365.37959839
  -117.47500556 66095.55238892  4027.66193935  1039.42061392]
```

IMPLEMENTASI PROGRAM

Pemodelan Regresi Menggunakan Python

2. Hasil Evaluasi Performa

Setelah proses pelatihan dan prediksi dilakukan, selanjutnya model dievaluasi menggunakan beberapa metrik, yaitu MAE, MSE, RMSE, dan R^2 Score.

In [10]:
```python
# 202431181_Zhalsabila Amalia Putri

# 5. Evaluasi Performa Model
mae = mean_absolute_error(y_test, y_pred)
mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
r2 = r2_score(y_test, y_pred)


print("HASIL MODEL REGRESI LINEAR")
print("Jumlah data keseluruhan:", len(model_data))
print("Jumlah data training:", len(x_train))
print("Jumlah data testing:", len(x_test))

print("\nPersamaan Regresi:")
print("Coefficient (Slope):", model.coef_[0])
print("Intercept:", model.intercept_)

print("\nEvaluasi Model:")
print("MAE :", mae)
print("MSE :", mse)
print("RMSE:", rmse)
print("R2 Score:", r2)
```

```
HASIL MODEL REGRESI LINEAR
Jumlah data keseluruhan: 37
Jumlah data training: 29
Jumlah data testing: 8

Persamaan Regresi:
Coefficient (Slope): 0.989118659450453
Intercept: -323.31059859661036

Evaluasi Model:
MAE : 479.43078479232986
MSE : 305255.04241685866
RMSE: 552.4989071634972
R2 Score: 0.9993550664629474
```

IMPLEMENTASI PROGRAM

Pemodelan Regresi Menggunakan Python

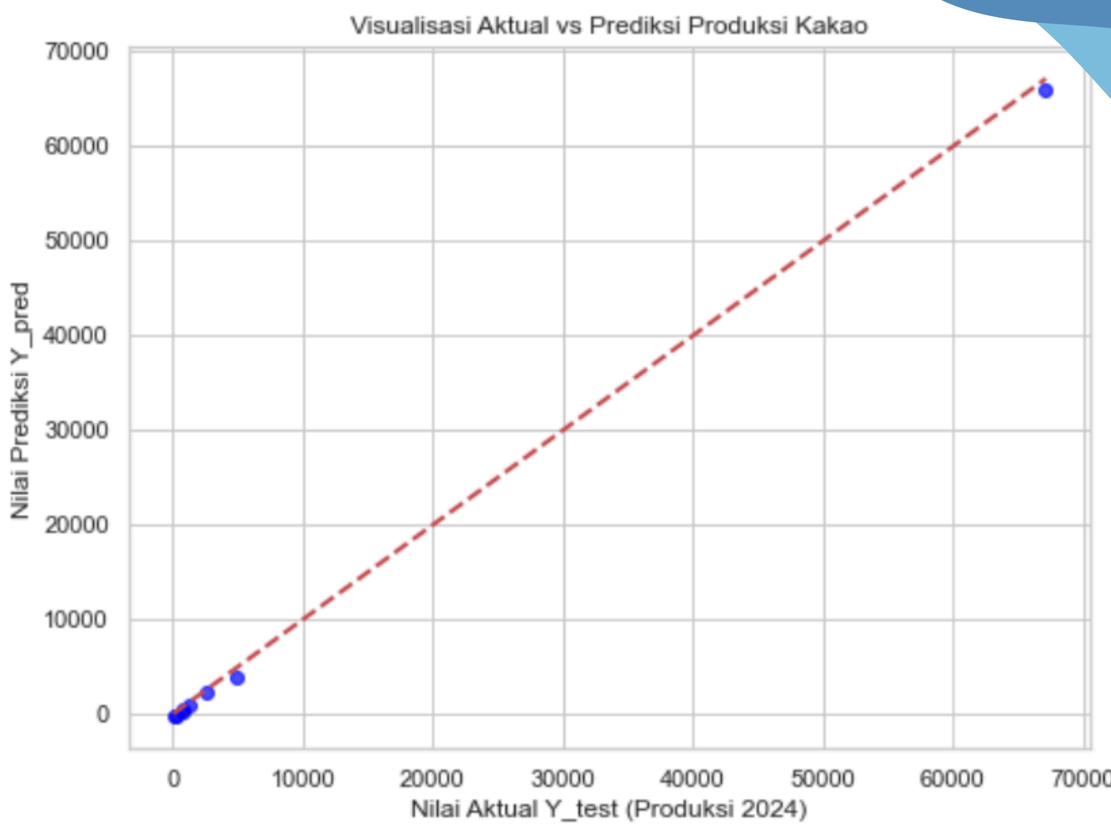
3. Visualisasi Grafik

In [11]:
```
# 202431181_Zhalsabila Amalia Putri

# 6. Visualisasi Grafik Aktual vs Prediksi

plt.figure(figsize=(8, 6))
plt.scatter(y_test, y_pred, alpha=0.7, color='blue')
plt.xlabel("Nilai Aktual Y_test (Produksi 2024)")
plt.ylabel("Nilai Prediksi Y_pred")
plt.title("Visualisasi Aktual vs Prediksi Produksi Kakao")
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], 'r--', lw=2)

plt.show()
```



EVALUASI PERFORMA

Hasil Evaluasi Performa Model

JUMLAH OBSERVASI DATA

37 Total **29 Data Latih** **8 Data Uji**

NILAI KOEFISIEN PYTHON

Slope: 0,9891 **Intercept: -323,31**

R^2 SCORE

0.999

Akurasi tinggi dalam menjelaskan variansi target

MAE

479.4

Rata-rata error absolut prediksi dalam Ton

RMSE

552.5

Akar kuadrat rata-rata selisih prediksi

SELESAI

Terima Kasih Atas Perhatian Anda

Zhalsabila Amalia Putri
NIM: 202431181
Kelas C